

TRPO 实验报告与复现思索

黄刘楷

2026 年 6 月 7 日

摘要

本文围绕 Trust Region Policy Optimization (TRPO) 的理论保证、采样方式、优势估计、信赖域约束以及实验曲线展开复现分析。与原始草稿相比，本版重点修正了公式与符号的排版，并加入 TensorBoard 训练曲线图像，对 HalfCheetah、Hopper、Humanoid、Walker2d 与 Ant 等环境中的性能差异、样本利用率和训练稳定性进行解释。

目录

1	采样与基础设定	2
2	TRPO 理论理解	2
2.1	TRPO 的核心理论保证	2
2.2	混合策略定理及局限性	2
2.3	TRPO 作者的核心改进	3
2.4	理论形式与可计算转化	3
2.5	为什么使用 KL 散度而不是 TV 距离?	4
3	环境与采样实验分析	5
3.1	不同环境的训练难度	5
3.2	Trajectory 与 Rollout 的样本利用率差异	6
3.3	Advantage 与 Return 的计算差异	8
3.4	Advantage Normalization 的影响	8
3.5	HalfCheetah 多组实验对比	9
4	总结与反思	9
4.1	采样实现是否改变 TRPO 的 on-policy 特性	9
4.2	如果只能保留一种采样方式	10
4.3	对 TRPO 的新认识	10
4.4	实现建议	10

1 采样与基础设定

在实验实现中，**trajectory** 与 **rollout** 是两种不同的数据收集方式。Trajectory 模式以完整 episode 为基本单位，一条轨迹会一直收集到环境终止或达到最大长度；rollout 模式则以固定 transition 数量为目标，达到预设步数后直接截断当前采样批次。

采样 buffer 中的核心变量包括状态 s_t 、动作 a_t 、奖励 r_t 、终止标记 $done_t$ 与掩码 $mask_t$ 。其中 $mask_t$ 的作用是区分有效 transition 与 padding 后的无效位置。若 trajectory 模式中某条轨迹提前结束，为了对齐 batch 张量形状，剩余位置会补零；这些补零位置必须通过 mask 屏蔽，否则会污染 return 与 advantage 的计算。

对于 GAE (Generalized Advantage Estimation)，掩码尤其关键。若不使用 mask，补零状态经过随机初始化的 value network 后通常不会刚好输出 0，从而在递推中引入虚假的 bootstrap 项。实验的基础假设是初始状态来自环境的稳态或默认初始分布，因此每次重置环境时都应遵循环境自身的初始化机制，避免人为造成状态分布偏移。

2 TRPO 理论理解

2.1 TRPO 的核心理论保证

TRPO 的核心理论保证是对策略性能提升给出一个可控下界。记旧策略为 π_{old} ，新策略为 π_{new} ，则有

$$\eta(\pi_{new}) \geq L_{\pi_{old}}(\pi_{new}) - \frac{4\epsilon\gamma}{(1-\gamma)^2}\alpha^2, \quad (1)$$

其中

- $\eta(\pi_{new})$ 表示新策略的真实期望累计折扣回报；
- $L_{\pi_{old}}(\pi_{new})$ 表示在旧策略分布下构造的 surrogate objective；
- $\epsilon = \max_{s,a} |A_{\pi_{old}}(s,a)|$ 表示优势函数绝对值上界；
- $\alpha = D_{TV}^{\max}(\pi_{old}, \pi_{new})$ 表示新旧策略之间的最大 total variation 距离。

如果新策略满足

$$L_{\pi_{old}}(\pi_{new}) - \frac{4\epsilon\gamma}{(1-\gamma)^2}\alpha^2 \geq \eta(\pi_{old}), \quad (2)$$

则可以保证策略性能单调不退步。TRPO 的设计思路正是最大化 surrogate objective，同时约束新旧策略之间的距离，使性能下界不会下降。

2.2 混合策略定理及局限性

在 *Approximately Optimal Approximate Reinforcement Learning* 的 Theorem 4.1 中，考虑一种特殊的混合策略：

$$\pi' = (1 - \alpha)\pi + \alpha\pi_{new}. \quad (3)$$

其性能下界可写为

$$\eta(\pi') \geq L_\pi(\pi') - \frac{2\epsilon\gamma\alpha^2}{(1-\gamma(1-\alpha))(1-\gamma)}. \quad (4)$$

该结论的推导高度依赖混合策略的凸组合结构。因为在此结构下，total variation 距离天然受到混合系数控制：

$$D_{\text{TV}}(\pi, \pi') \leq \alpha. \quad (5)$$

然而，深度强化学习中的策略通常由神经网络参数化，不具备显式凸组合形式。因此该定理不能直接用于一般的神经网络随机策略。

2.3 TRPO 作者的核心改进

Schulman 等人在 TRPO 中将上述理论推广到任意随机策略。关键改进在于不再假设策略具有混合结构，而是直接将 α 定义为最大 total variation 距离：

$$\alpha = D_{\text{TV}}^{\max}(\pi_{\text{old}}, \pi_{\text{new}}) = \max_s D_{\text{TV}}(\pi_{\text{old}}(\cdot|s), \pi_{\text{new}}(\cdot|s)). \quad (6)$$

这样， α 不再是混合系数，而是任意两个动作分布之间的几何距离。

TRPO 还重新分析了新旧策略下状态访问分布的偏移：

$$\|d^{\pi_{\text{new}}}(s) - d^{\pi_{\text{old}}}(s)\|, \quad (7)$$

并证明时间维度上的累积误差可以由 $O(\alpha^2)$ 控制。最终得到适用于任意随机策略的性能界：

$$\eta(\pi) \geq L_{\pi_{\text{old}}}(\pi) - \frac{4\epsilon\gamma}{(1-\gamma)^2}\alpha^2. \quad (8)$$

2.4 理论形式与可计算转化

TRPO 理论中的替代目标函数定义为

$$L_{\pi_{\text{old}}}(\pi_{\text{new}}) = \eta(\pi_{\text{old}}) + \sum_s d^{\pi_{\text{old}}}(s) \sum_a \pi_{\text{new}}(a|s) A_{\pi_{\text{old}}}(s, a). \quad (9)$$

由于真实状态访问分布 $d^{\pi_{\text{old}}}(s)$ 无法精确获得，工程实现中使用旧策略采样轨迹进行蒙特卡洛估计。同时，动作空间求和可通过重要性采样转化为

$$\sum_a \pi_{\text{new}}(a|s) A(s, a) = \mathbb{E}_{a \sim \pi_{\text{old}}} \left[\frac{\pi_{\text{new}}(a|s)}{\pi_{\text{old}}(a|s)} A(s, a) \right]. \quad (10)$$

将策略写作参数化形式 π_θ 后，经验估计为

$$L_{\pi_{\text{old}}}(\pi_\theta) \approx \eta(\pi_{\text{old}}) + \mathbb{E} \left[\frac{\pi_\theta(a_t|s_t)}{\pi_{\text{old}}(a_t|s_t)} A_t \right]. \quad (11)$$

因为 $\eta(\pi_{\text{old}})$ 对当前参数 θ 的梯度为零:

$$\nabla_{\theta} \eta(\pi_{\text{old}}) = 0, \quad (12)$$

实现中通常直接最大化经验替代目标

$$\hat{L}(\theta) = \frac{1}{N} \sum_{t=1}^N r_t(\theta) A_t, \quad r_t(\theta) = \frac{\pi_{\theta}(a_t|s_t)}{\pi_{\text{old}}(a_t|s_t)}. \quad (13)$$

其中 A_t 常由 GAE 得到, 记作 $A_t^{\text{GAE}(\lambda)}$ 。

2.5 为什么使用 KL 散度而不是 TV 距离?

由 Pinsker 不等式可知, total variation 距离与 KL 散度满足

$$D_{\text{TV}}(p, q) \leq \sqrt{\frac{1}{2} D_{\text{KL}}(p||q)}. \quad (14)$$

TV 距离在连续空间中通常不光滑, 难以高效求梯度或做二阶近似; 而 KL 散度具有良好的可微性, 并且对于高斯策略等常见策略分布存在闭式表达。

在当前参数 θ_{old} 邻域内, 对 KL 散度做二阶泰勒展开:

$$D_{\text{KL}}(\theta_{\text{old}}, \theta) \approx \frac{1}{2} \Delta \theta^{\top} F \Delta \theta, \quad (15)$$

其中

$$F = \nabla_{\theta}^2 D_{\text{KL}}(\theta_{\text{old}}, \theta) \big|_{\theta=\theta_{\text{old}}} \quad (16)$$

对应 Fisher Information Matrix (FIM)。于是信赖域约束可写为椭球约束:

$$\frac{1}{2} \Delta \theta^{\top} F \Delta \theta \leq \delta. \quad (17)$$

在局部线性化目标下, TRPO 求解

$$\max_{\Delta \theta} g^{\top} \Delta \theta \quad \text{s.t.} \quad \frac{1}{2} \Delta \theta^{\top} F \Delta \theta \leq \delta. \quad (18)$$

其方向为自然梯度方向:

$$\Delta \theta_{\text{base}} = F^{-1} g, \quad (19)$$

并通过缩放得到满足约束的最大步长:

$$\Delta \theta^* = \sqrt{\frac{2\delta}{\Delta \theta_{\text{base}}^{\top} F \Delta \theta_{\text{base}}}} \Delta \theta_{\text{base}}. \quad (20)$$

由于二阶近似在步长较大时可能失效，工程实现中还需要回溯线性搜索：

$$\theta_k = \theta_{\text{old}} + \beta^k \Delta \theta^*, \quad \beta \in (0, 1). \quad (21)$$

每个候选步长都需要同时满足真实 KL 约束

$$D_{\text{KL}}^{\text{real}}(\theta_{\text{old}}, \theta_k) \leq \delta \quad (22)$$

以及 surrogate objective 不下降。算法最终选择满足双重条件的最大步长更新策略参数。

3 环境与采样实验分析

实验选取 HalfCheetah-v5、Hopper-v5、Humanoid-v5、Walker2d-v5 与 Ant-v5。图中的纵轴为测试平均 episode reward，横轴为 environment step。

3.1 不同环境的训练难度




图 1: HalfCheetah-v5 单次 TRPO 训练曲线。

如图 1 所示，HalfCheetah-v5 的 reward 在前 10M step 左右快速增长，随后逐渐进入平台期，并在 70M step 附近达到约 4.6×10^3 。这说明 HalfCheetah 的奖励较稠密、状态转移平滑、没有明显早停惩罚，TRPO 可以较稳定地获得有效梯度。




图 2: Ant-v5 单次 TRPO 训练曲线。

图 2 中 Ant-v5 的训练曲线整体单调上升，在 60M step 后接近 5.0×10^3 。与 Hopper 相比，Ant 的曲线虽然仍存在局部回撤，但全局趋势更平滑，说明该设置下策略更新没有频繁突破信赖域导致性能崩塌。

3.2 Trajectory 与 Rollout 的样本利用率差异




图 3: HalfCheetah-v5 中 rollout 与 trajectory 的对比。橙色为 rollout，深蓝色为 trajectory。

图 3 显示，在 HalfCheetah-v5 中，rollout 和 trajectory 都能稳定提升，但 rollout 最终回报明显更高：rollout 的 smoothed reward 约为 4207，trajectory 约为 3540。这说明即使在无明显早停的平滑环境中，固定步长 rollout 也可能由于每轮更新获得更稳定、规模更固定的数据而取得更高样本效率。




图 4: Hopper-v5 中 rollout 与 trajectory 的对比。

Hopper-v5 的差异最明显。图 4 中，两条曲线早期都能快速到达 3000 以上，但随后出现明显退化；其中 trajectory 组在约 36M step 时已下降到 1852 左右，而 rollout 组虽然最终也退化到约 1573，但训练长度更长。Hopper 容易因为摔倒触发 early termination，trajectory 模式会产生大量短轨迹和 padding，无效 transition 比例增加，进而降低梯度质量。




图 5: Humanoid-v5 中 rollout 与 trajectory 的对比。紫色为 rollout，绿色为 trajectory。

图 5 展示了高维任务中的巨大差异。Rollout 模式能从约 200 稳定提升到 1000 以上，而 trajectory 模式只训练到约 6.75M step，最终 smoothed reward 约为 578。Humanoid 的状态与动作维度高，完整轨迹收集成本大且方差高；rollout 通过固定样本量保证每次更新都有足够 transition，因此更容易持续改进。

3.3 Advantage 与 Return 的计算差异

Trajectory 模式基于完整 episode。若遇到终止状态 $\text{done} = 1$ ，其后续 value 严格置为 0，return 可以写为

$$G_t = \sum_{l=0}^{T-t-1} \gamma^l r_{t+l}. \quad (23)$$

GAE 的递推项为

$$\delta_t = r_t + \gamma V(s_{t+1})(1 - \text{done}_t) - V(s_t), \quad (24)$$

$$A_t = \delta_t + \gamma \lambda (1 - \text{done}_t) A_{t+1}. \quad (25)$$

Rollout 模式则可能在人为截断处终止采样，此时物理 episode 未必结束。因此最后一个状态需要使用 critic 自举：

$$G_T \approx V(s_T). \quad (26)$$

如果将人为截断误当作真实终止，就会把 $V(s_T)$ 错误置零，引入严重的 truncation bias。

3.4 Advantage Normalization 的影响




图 6: Walker2d-v5 中 advantage normalization 对训练曲线的影响。青色曲线最终高于粉色曲线。

图 6 表明，在 Walker2d-v5 这类动态平衡环境中，开启 advantage normalization 的曲线整体更高且更稳定，最终 smoothed reward 约为 4700；另一组约为 4312，且训练在 50M step 附近结束。其原因是未归一化的 advantage 绝对值可能过大，使 surrogate objective 的梯度尺度剧烈波动，从而使 KL divergence 出现尖峰，破坏 TRPO 的信赖域假设。归一化后，优势估计变为

$$\tilde{A}_t = \frac{A_t - \mu_A}{\sigma_A + \varepsilon}, \quad (27)$$

梯度方向保留相对优劣信息，但尺度更稳定。

不过 advantage normalization 并非总能提升最终性能。对于 HalfCheetah 这类奖励稠密、

动力学平滑、没有摔倒早停的环境，advantage 的 batch 方差本身较小，强行归一化可能抹平优秀动作与普通动作之间的细粒度差异，从而限制策略继续探索更高回报。

3.5 HalfCheetah 多组实验对比




图 7: HalfCheetah-v5 三组实验对比。黄色为新一轮 TRPO，橙色为 rollout，深蓝色为 trajectory。

图 7 将三组 HalfCheetah 实验放在同一坐标中。黄色曲线最终 smoothed reward 约为 4593，显著高于旧 rollout 的 4207 和 trajectory 的 3540。这说明在同一算法框架下，超参数、随机种子、采样设置或训练时长都会影响最终性能。更重要的是，三条曲线的相对排序显示：在该实验设置中，固定步长 rollout 和更充分的训练配置比完整 trajectory 更容易取得高回报。

4 总结与反思

4.1 采样实现是否改变 TRPO 的 on-policy 特性

只要每次策略更新后丢弃旧数据，并用最新策略 π_{θ_k} 重新采样，trajectory 与 rollout 都不会改变 TRPO 的 on-policy 属性。关键不在于轨迹是否完整，而在于数据是否来自当前待优化策略。

4.2 如果只能保留一种采样方式

从实验结果看, rollout 更适合作为默认选择。它保证每次更新都有固定数量的有效 transition, 几乎不产生 padding 浪费; 在 Hopper 和 Humanoid 这类早停或高维环境中, 这种稳定的数据供给显著优于完整 trajectory。Trajectory 的优势在于完整回合 return 更接近无偏估计, 但这一优势主要在无早停、方差较低的环境中才容易体现。

4.3 对 TRPO 的新认识

TRPO 的核心并不只是“限制 KL 散度”, 而是把难以直接优化的真实性能目标转化为 surrogate objective 与信赖域约束之间的平衡。重要性采样、二阶 KL 近似、Fisher-vector product、共轭梯度和回溯线性搜索共同构成了这套理论到工程的闭环。

实验也说明, 强化学习中的直觉经常需要被数据修正。完整 trajectory 在理论上更自然, 但在存在 early termination 的任务中可能因为短轨迹和 padding 造成严重样本浪费; rollout 虽然引入 bootstrap bias, 却在多数工程场景中更稳健。

4.4 实现建议

后续实现或教学文档中, 建议更明确地区分以下细节:

- trajectory 模式下 padding 与 mask 的交互关系;
- rollout 截断处 bootstrap value 的处理方式;
- line search 的两个判定条件: 真实 KL 合法与 surrogate objective 不下降;
- advantage normalization 对不同环境的影响并不一致, 应结合环境奖励稠密程度与早停机制判断。